

**BANKA PAZARLAMA KAMPANYALARINDA
MÜŞTERİ DAVRANIŞ ANALİZİ VE
MAKİNE ÖĞRENMESİ İLE
VADELİ MEVDUAT TAHMİNİ**

**Yönetim Bilişim Sistemleri
Veri Analitiği ve Makine Öğrenmesi Projesi**

Hazırlayan:
Nehir Girgin

Bölüm:
Yönetim Bilişim Sistemleri

Tarih:
Mayıs 2026

İÇİNDEKİLER

Özet	
Abstract	
1. Giriş	
2. Problem Tanımı	
3. Veri Setinin Tanıtılması	
3.1 Veri Seti Hakkında Genel Bilgiler	
3.2 Değişkenlerin Açıklanması	
4. Veri Ön İşleme (Data Preprocessing)	
4.1 Veri Temizleme İşlemleri	
4.2 Eksik Veri Analizi	
4.3 Aykırı Değer (Outlier) Analizi	
4.4 Özellik Mühendisliği (Feature Engineering)	
4.5 Encoding ve Veri Dönüşümleri	
5. Modelleme	
5.1 Eğitim ve Test Verisinin Oluşturulması	
5.2 Makine Öğrenmesi Modellerinin Oluşturulması	
5.2.1 Logistic Regression	
5.2.2 Random Forest	
5.2.3 SMOTE Sonrası Random Forest Modeli	
5.2.4 XGBoost Modeli	
5.2.5 Support Vector Machine (SVM)	
5.3 Modellerin Karşılaştırılması	
5.4 XGBoost Modelinde Özellik Önem Düzeyleri	
6. Sonuç ve Değerlendirme	
Kaynakça	

ÖZET

Bu çalışmada, bir bankanın doğrudan pazarlama kampanyaları kapsamında müşterilerin vadeli mevduat hesabı açma davranışlarının tahmin edilmesi amaçlanmıştır. Çalışmada kullanılan veri seti üzerinde veri ön işleme, aykırı değer analizi, özellik mühendisliği (feature engineering), keşifsel veri analizi (Exploratory Data Analysis - EDA) ve makine öğrenmesi uygulamaları gerçekleştirilmiştir.

Veri ön işleme sürecinde eksik veri kontrolü, aykırı değer baskılama işlemleri ve kategorik değişken dönüşümleri uygulanmıştır. Ayrıca müşteri davranışlarını daha iyi analiz edebilmek amacıyla yaş grupları, mevsimsel değişkenler ve müşteri segmentasyonu odaklı yeni özellikler oluşturulmuştur.

Keşifsel veri analizi sürecinde müşterilerin yaş, eğitim durumu, medeni durum, meslek, ekonomik göstergeler ve geçmiş kampanya sonuçlarına göre davranışları detaylı olarak incelenmiştir. Elde edilen bulgular doğrultusunda müşterilerin kampanyalara verdikleri tepkiler üzerinde özellikle ekonomik göstergelerin, önceki kampanya başarılarının ve iletişim süresinin önemli etkileri olduğu gözlemlenmiştir.

Makine öğrenmesi aşamasında Logistic Regression, Random Forest, Support Vector Machine (SVM) ve XGBoost algoritmaları kullanılarak modeller geliştirilmiş ve performans karşılaştırmaları gerçekleştirilmiştir. Ayrıca sınıf dengesizliği problemini azaltmak amacıyla SMOTE yöntemi uygulanmıştır. Yapılan analizler sonucunda en başarılı performansın ensemble tabanlı modeller tarafından elde edildiği görülmüştür.

Bu çalışma, bankacılık sektöründe veri analitiği ve makine öğrenmesi yöntemlerinin müşteri hedefleme süreçlerinde etkili biçimde kullanılabileceğini göstermektedir. Elde edilen sonuçların kampanya maliyetlerini azaltma, müşteri segmentasyonunu iyileştirme ve pazarlama stratejilerini optimize etme açısından karar vericilere katkı sağlayabileceği değerlendirilmektedir.

Anahtar Kelimeler: Veri Analitiği, Makine Öğrenmesi, Bankacılık, Müşteri Segmentasyonu, XGBoost, Pazarlama Analitiği, Sınıflandırma, Veri Madenciliği

ABSTRACT

This study aims to predict whether customers will subscribe to a term deposit product within the scope of a bank marketing campaign. In this study, data preprocessing, outlier analysis, feature engineering, exploratory data analysis (EDA), and machine learning applications were performed on the selected dataset.

During the data preprocessing stage, missing value control, outlier suppression, and categorical variable transformations were applied. In addition, new variables focusing on customer segmentation, seasonal effects, and age groups were created in order to better analyze customer behaviors.

Within the exploratory data analysis process, customer behaviors were examined in detail according to age, education level, marital status, occupation, economic indicators, and previous campaign outcomes. The findings revealed that economic indicators, previous campaign success, and communication duration had significant effects on customer responses to marketing campaigns.

In the machine learning phase, Logistic Regression, Random Forest, Support Vector Machine (SVM), and XGBoost algorithms were implemented and compared. Furthermore, the SMOTE technique was applied to reduce the class imbalance problem. As a result of the analyses, ensemble-based models achieved the highest performance.

The results of this study demonstrate that data analytics and machine learning methods can effectively support customer targeting processes in the banking sector. The findings may contribute to reducing campaign costs, improving customer segmentation, and optimizing marketing strategies for decision-makers.

Keywords: Data Analytics, Machine Learning, Banking, Customer Segmentation, XGBoost, Marketing Analytics, Classification, Data Mining

1. GİRİŞ


Bankacılık sektörü, dijital dönüşüm ve veri odaklı karar verme süreçlerinin hız kazanmasıyla birlikte büyük miktarda müşteri verisini analiz eden sektörlerin başında gelmektedir. Özellikle doğrudan pazarlama kampanyalarında doğru müşterinin hedeflenmesi, hem maliyetlerin azaltılması hem de müşteri memnuniyetinin artırılması açısından kritik öneme sahiptir. Geleneksel pazarlama yöntemleri çoğu zaman yüksek maliyetli ve düşük dönüşüm oranlarına sahip olabilmektedir. Bu nedenle bankalar, müşteri davranışlarını analiz ederek daha etkili pazarlama stratejileri geliştirmeye yönelmektedir.

Veri analitiği ve makine öğrenmesi yöntemleri, büyük veri kümeleri içerisindeki örüntüleri keşfetme ve geleceğe yönelik tahminlerde bulunma konusunda önemli avantajlar sağlamaktadır. Özellikle müşteri segmentasyonu, davranış analizi ve satın alma eğilimi tahmini gibi alanlarda makine öğrenmesi algoritmaları yaygın biçimde kullanılmaktadır. Bankacılık sektöründe bu teknolojilerin kullanımı; müşteri kaybını azaltma, kampanya başarı oranını artırma ve kişiselleştirilmiş hizmet sunma açısından önemli katkılar sağlamaktadır.

Bu çalışmada, bir bankanın pazarlama kampanyalarına ait müşteri verileri kullanılarak müşterilerin vadeli mevduat hesabı açma olasılıklarının tahmin edilmesi amaçlanmıştır. Çalışma kapsamında veri ön


işleme, keşifsel veri analizi, özellik mühendisliği ve makine öğrenmesi yöntemleri uygulanmıştır. Ayrıca farklı sınıflandırma algoritmalarının performansları karşılaştırılarak en başarılı model belirlenmeye çalışılmıştır.

Çalışmanın temel amacı, bankacılık sektöründe veri analitiği ve makine öğrenmesi yöntemlerinin müşteri hedefleme süreçlerindeki etkinliğini incelemek ve kampanya optimizasyonuna katkı sağlayabilecek stratejik çıkarımlar elde etmektir.



Şekil 1. Çalışmada Uygulanan Veri Analizi ve Makine Öğrenmesi Süreci

Çalışma kapsamında veri setindeki değişkenler arasındaki ilişkilerin daha iyi anlaşılabilmesi amacıyla korelasyon analizi gerçekleştirilmiştir. Korelasyon matrisi, hedef değişken ile diğer değişkenler arasındaki ilişkilerin incelenmesine katkı sağlamaktadır.



Şekil 2. Vadeli Mevduat Kabulünü Etkileyen Faktörlerin Korelasyon Matrisi


2. PROBLEM TANIMI

Bankacılık sektöründe gerçekleştirilen doğrudan pazarlama kampanyalarının temel amacı, doğru müşterilere ulaşarak ürün kabul oranlarını artırmaktır. Ancak geniş müşteri kitlelerine uygulanan kampanyalar yüksek operasyonel maliyetlere ve düşük geri dönüş oranlarına neden olabilmektedir. Özellikle kampanya ile ilgilenmeyen müşterilere yapılan gereksiz aramalar hem zaman hem de maliyet kaybına yol açarken, müşteri memnuniyetini de olumsuz etkileyebilmektedir. Bu nedenle bankalar, müşteri davranışlarını önceden analiz ederek daha doğru hedefleme stratejileri geliştirmeye yönelmektedir.

Bu çalışmada ele alınan problem, bir bankanın müşterilerinin vadeli mevduat hesabı açıp açmayacağını önceden tahmin edilmesidir. Problem, makine öğrenmesi alanında ikili sınıflandırma (Binary Classification) problemi olarak ele alınmıştır. Hedef değişken olan “y” değişkeni müşterinin kampanyaya olumlu ya da olumsuz yanıt verdiğini göstermektedir. “yes” değeri müşterinin vadeli mevduat hesabı açtığını, “no” değeri ise kampanyayı kabul etmediğini ifade etmektedir.

Çalışma kapsamında müşteri demografik bilgileri, ekonomik göstergeler, geçmiş kampanya sonuçları ve iletişim verileri kullanılarak müşteri davranışları analiz edilmiştir. Elde edilen bulgular doğrultusunda müşterilerin kampanyaya olumlu dönüş yapma olasılıklarının tahmin edilmesi amaçlanmıştır. Ayrıca farklı makine öğrenmesi algoritmalarının performansları karşılaştırılarak en başarılı modelin belirlenmesi hedeflenmiştir.

Veri setindeki hedef değişken dağılımı incelendiğinde kampanyaya olumlu yanıt veren müşteri sayısının, olumsuz yanıt veren müşteri sayısına göre oldukça düşük olduğu görülmektedir. Bu durum veri setinde sınıf dengesizliği (Class Imbalance) problemi bulunduğunu göstermektedir. Sınıf dengesizliği problemi, makine öğrenmesi modellerinin performansını etkileyebileceğinden çalışma kapsamında ayrıca ele alınmıştır.



Şekil 3. Vadeli Mevduat Kampanyasına Verilen Yanıtların Dağılımı

3. Veri Setinin Tanıtılması

3.1 Veri Seti Hakkında Genel Bilgiler

Bu çalışmada kullanılan veri seti, bir bankanın doğrudan pazarlama kampanyalarına ait müşteri verilerinden oluşmaktadır. Veri setinde müşterilerin demografik bilgileri, ekonomik göstergeler, iletişim bilgileri ve geçmiş kampanya sonuçlarına ilişkin değişkenler bulunmaktadır. Çalışmanın temel amacı, müşterilerin vadeli mevduat kampanyasına olumlu yanıt verip vermeyeceğinin tahmin edilmesidir.

Veri seti hem sayısal hem de kategorik deęişkenlerden oluşmaktadır. Veri içerisinde müşteri yaşı, meslek bilgisi, medeni durum, eğitim seviyesi, görüşme süresi, kampanya iletişim sayısı ve ekonomik göstergeler gibi müşteri davranışını etkileyebilecek birçok deęişken yer almaktadır. Hedef deęişken olan “y” deęişkeni, müşterinin kampanyaya olumlu ya da olumsuz yanıt verdiğini göstermektedir.

Veri seti toplam 41.188 gözlem ve 21 deęişkenden oluşmaktadır. Veri setinde hem sayısal hem de kategorik deęişkenler yer almakta olup müşteri davranışlarını etkileyebilecek demografik, ekonomik ve kampanya odaklı bilgiler bulunmaktadır.

Tablo 1. Veri Setinin Genel Özellikleri

Özellik	Değer
Veri Seti Türü	Banka Pazarlama Verisi
Gözlem Sayısı	41.188
Değişken Sayısı	21
Problem Türü	İkili Sınıflandırma (Binary Classification)
Hedef Değişken	y
Veri Türü	Sayısal ve Kategorik
Analiz Türü	Veri Analitięi ve Makine Öğrenmesi

Tablo 2. Veri Setinin İlk 5 Gözlemi

	age	job	marital	education	default	housing	loan	contact	month	day_of_week	duration	campaign
0	56	housemaid	married	basic.4y	no	no	no	telephone	may	mon	261	1
1	57	services	married	high.school	unknown	no	no	telephone	may	mon	149	1
2	37	services	married	high.school	no	yes	no	telephone	may	mon	226	1
3	40	admin.	married	basic.6y	no	no	no	telephone	may	mon	151	1
4	56	services	married	high.school	no	no	yes	telephone	may	mon	307	1

pdays	previous	poutcome	emp.var.rate	cons.price.idx	cons.conf.idx	euribor3m	nr.employed	y
999	0	nonexistent	1	94	-36	5	5,191	no
999	0	nonexistent	1	94	-36	5	5,191	no
999	0	nonexistent	1	94	-36	5	5,191	no
999	0	nonexistent	1	94	-36	5	5,191	no
999	0	nonexistent	1	94	-36	5	5,191	no

Tablo 3. Değişkenlerin Açıklanması Tablosu.

Veri setinde müşteri davranışlarını etkileyebilecek demografik, ekonomik ve kampanya odaklı değişkenler bulunmaktadır. Çalışmada kullanılan değişkenlerin açıklamaları aşağıdaki tabloda verilmiştir.

Değişken	Açıklama
age	Müşteri yaşı
job	Müşterinin mesleği
marital	Medeni durum
education	Eğitim seviyesi
default	Kredi temerrüt durumu
housing	Konut kredisi durumu
loan	Bireysel kredi durumu
contact	İletişim türü

Değişken	Açıklama
month	Son iletişim ayı
day_of_week	Son iletişim günü
duration	Görüşme süresi (saniye)
campaign	Kampanya süresince yapılan iletişim sayısı
pdays	Önceki kampanyadan sonra geçen gün sayısı
previous	Önceki iletişim sayısı
poutcome	Önceki kampanya sonucu
emp.var.rate	İstihdam değişim oranı
cons.price.idx	Tüketici fiyat endeksi
cons.conf.idx	Tüketici güven endeksi
euribor3m	3 aylık Euribor faiz oranı
nr.employed	Çalışan sayısı göstergesi
y	Kampanya sonucu (hedef değişken)

4. Veri Ön İşleme (Data Preprocessing)

Makine öğrenmesi modellerinin başarılı sonuçlar üretebilmesi için veri setinin analiz öncesinde uygun şekilde hazırlanması gerekmektedir. Ham veri setleri eksik veriler, aykırı değerler, tutarsız kayıtlar ve model performansını olumsuz etkileyebilecek çeşitli problemler içerebilmektedir. Bu nedenle çalışma kapsamında veri seti üzerinde veri temizleme, dönüştürme ve düzenleme işlemleri gerçekleştirilmiştir.


Veri ön işleme sürecinde yaş filtresi uygulanmış, aykırı değer analizleri gerçekleştirilmiş, kategorik değişken dönüştürmeleri yapılmış ve modelleme sürecini desteklemek amacıyla yeni özellikler oluşturulmuştur. Ayrıca veri setindeki sınıf yapısı ve değişken ilişkileri dikkate alınarak makine öğrenmesi sürecine uygun hale getirilmiştir.

4.1 Veri Temizleme İşlemleri

Çalışma kapsamında veri setinde bulunan yaş değişkeni incelenmiş ve 18 yaş altındaki kayıtlar veri setinden çıkarılmıştır.

```
df = df[df["age"] >= 18]
df = df.reset_index(drop=True)
```

Kod Bloğu 1. Yaş Filtresi Uygulaması ve İndeks Düzenleme İşlemi



Şekil 4. Yaş Değişkeninin Dağılımı

Yaş değişkeninin dağılımı incelendiğinde müşteri yoğunluğunun özellikle 30–50 yaş aralığında toplandığı görülmektedir. Veri setinde ileri yaş gruplarına ait müşteri sayısının daha düşük olduğu gözlemlenmiştir. Ayrıca yaş değişkeninde sağa çarpık bir dağılım yapısı bulunduğu dikkat çekmektedir.

4.2 Eksik Veri Analizi

Veri ön işleme sürecinde veri setindeki eksik veriler analiz edilmiştir. Eksik veriler, makine öğrenmesi modellerinin performansını olumsuz etkileyebileceği için veri kalitesinin kontrol edilmesi büyük önem

taşımaktadır. Bu kapsamda veri setindeki tüm değişkenler incelenmiş ve eksik veri kontrolü gerçekleştirilmiştir.

Yapılan analiz sonucunda veri setinde eksik veri bulunmadığı tespit edilmiştir. Tüm değişkenlerde eksik veri sayısının sıfır olduğu görülmüştür. Bu durum veri setinin analiz ve modelleme süreçleri açısından uygun bir veri kalitesine sahip olduğunu göstermektedir.

```
df.isnull().sum()

age          0
job          0
marital      0
education    0
default      0
housing      0
loan         0
contact      0
month        0
day_of_week  0
campaign     0
pdays_contacted 0
previous     0
poutcome     0
emp.var.rate 0
cons.price.idx 0
cons.conf.idx 0
euribor3m    0
nr.employed  0
y            0
dtype: int64
```

Kod Bloğu 2. Eksik Veri Kontrolü

4.3 Aykırı Değer (Outlier) Analizi


Makine öğrenmesi modellerinin performansını olumsuz etkileyebilecek aykırı değerlerin tespit edilmesi amacıyla veri seti üzerinde aykırı değer analizi gerçekleştirilmiştir. Çalışmada IQR (Interquartile Range) yöntemi kullanılarak aykırı değer sınırları belirlenmiş ve ilgili değişkenlerde baskılama işlemi uygulanmıştır.

Ayrıca dağılımı bozuk olan değişkenlerin daha dengeli hale getirilmesi amacıyla logaritmik dönüşüm işlemleri gerçekleştirilmiştir. Özellikle “campaign” değişkeninde yüksek sağa çarpıklık gözlemlendiği için log dönüşümü uygulanmıştır.

```
df[col] = df[col].clip(lower=low_limit, upper=up_limit)

if df['campaign'].max() > 10:
    df['campaign'] = np.log1p(df['campaign'])
```

Kod Bloğu 3. Aykırı Değer Baskılama ve Logaritmik Dönüşüm İşlemleri



Şekil 5. Aykırı Değer Baskılama ve Logaritmik Dönüşüm Öncesi/Sonrası Karşılaştırmaları

4.4 Özellik Mühendisliği (Feature Engineering)

Makine öğrenmesi modellerinin veri içerisindeki örüntüleri daha iyi öğrenebilmesi amacıyla veri seti üzerinde özellik mühendisliği işlemleri gerçekleştirilmiştir. Özellik mühendisliği sürecinde mevcut

değişkenlerden yeni değişkenler türetilmiş ve müşteri davranışlarını daha iyi temsil edebilecek yapılar oluşturulmuştur.

Bu kapsamda yaş grupları oluşturulmuş, mevsimsel değişkenler türetilmiş, emeklilik durumunu temsil eden değişkenler oluşturulmuş ve önceki kampanya iletişim bilgileri yeniden düzenlenmiştir. Böylece veri setinin modelleme sürecine daha uygun hale getirilmesi amaçlanmıştır.


Tablo 4. Özellik Mühendisliği Sonucunda Oluşturulan Yeni Değişkenler

Yeni Değişken	Açıklama
age_group	Müşterilerin yaş gruplarına ayrılması
season	İletişim ayına göre oluşturulan mevsim bilgisi
is_senior_retired	İleri yaş ve emeklilik durumunu temsil eden değişken
pdays_contacted	Önceki kampanyada müşteriyle iletişim kurulup kurulmadığını gösteren değişken

```
df['pdays_contacted'] = df['pdays'].apply(lambda x: 0 if x == 999 else 1)
```

```
df['is_senior_retired'] = ((df['age'] >= 60) & (df['job'] == 'retired')).astype(int)
print(f"Yeni 'is_senior_retired' sütunundaki dağılım:\n{df['is_senior_retired'].value_counts()}")
```

Kod Bloğu 4. Özellik Mühendisliği İşlemlerine Ait Örnek Kodlar



Şekil 6. Yaş Gruplarına Göre Vadeli Mevduat Kampanyası Kabul Oranları

Yaş grupları bazında gerçekleştirilen analiz sonucunda farklı yaş segmentlerinin kampanyalara farklı düzeylerde yanıt verdiği gözlemlenmiştir. Özellikle yaşlı müşteri grubunda kampanya kabul oranının diğer yaş gruplarına göre daha yüksek olduğu dikkat çekmektedir. Bu durum, yaş değişkeninin müşteri davranışlarını etkileyen önemli faktörlerden biri olduğunu göstermektedir.

4.5 Encoding ve Veri Dönüşümleri

Makine öğrenmesi algoritmalarının kategorik verilerle doğrudan çalışamaması nedeniyle veri setindeki kategorik değişkenler sayısal formata dönüştürülmüştür. Bu süreçte kategorik değişkenlerin yapısına uygun encoding yöntemleri kullanılmıştır.

Özellikle nominal kategorik değişkenlerde One-Hot Encoding yöntemi tercih edilmiştir. Böylece kategorik veriler modele uygun hale getirilmiş ve değişkenler arasındaki anlamsız sıralama probleminin önüne geçilmiştir. Ayrıca hedef değişken olan “y” değişkeni de sayısal forma dönüştürülerek modelleme sürecine hazırlanmıştır.

```
df_encoded = pd.get_dummies(df, columns=all_categorical_cols, drop_first=True)
```

```
df['y'] = df['y'].map({'yes': 1, 'no': 0})
```

Kod Bloğu 5. Encoding ve Hedef Değişken Dönüşüm İşlemleri

5. MODELLEME

Veri ön işleme ve özellik mühendisliği işlemlerinin tamamlanmasının ardından makine öğrenmesi modelleme sürecine geçilmiştir. Bu aşamada veri seti eğitim ve test verileri olarak ayrılmış, sınıf dengesizliği problemi için SMOTE yöntemi uygulanmış ve farklı makine öğrenmesi algoritmaları kullanılarak modeller oluşturulmuştur.

Çalışma kapsamında Logistic Regression, Random Forest, XGBoost ve Support Vector Machine (SVM) algoritmaları kullanılmıştır. Modellerin performansları çeşitli değerlendirme metrikleri kullanılarak karşılaştırılmış ve en başarılı model belirlenmiştir.

5.1 Eğitim ve Test Verisinin Oluşturulması

Makine öğrenmesi modellerinin performanslarının sağlıklı şekilde değerlendirilebilmesi amacıyla veri seti eğitim ve test verileri olarak ikiye ayrılmıştır. Eğitim verisi modelin öğrenme sürecinde kullanılırken, test verisi model performansının değerlendirilmesi amacıyla kullanılmıştır.

Çalışmada veri setinin %80'i eğitim verisi, %20'si ise test verisi olarak ayrılmıştır. Böylece modelin daha önce görmediği veriler üzerindeki başarısı analiz edilmiştir.

```
from sklearn.model_selection import train_test_split

X = df_encoded.drop('y', axis=1)
y = df_encoded['y']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.20, random_state=42)

print(f"Eğitim seti boyutu: {X_train.shape}")
print(f"Test seti boyutu: {X_test.shape}")
```

```
Eğitim seti boyutu: (32946, 59)
Test seti boyutu: (8237, 59)
```

Kod Bloğu 6. Eğitim ve Test Verisinin Oluşturulması

5.2 Makine Öğrenmesi Modellerinin Oluşturulması

Çalışma kapsamında farklı makine öğrenmesi algoritmaları kullanılarak sınıflandırma modelleri oluşturulmuştur. Modellerin amacı, müşterilerin vadeli mevduat kampanyasına olumlu yanıt verip vermeyeceğini tahmin etmektir.

Çalışma kapsamında Logistic Regression, Random Forest, XGBoost ve Support Vector Machine (SVM) algoritmaları kullanılmıştır. Modellerin performansları accuracy, precision, recall, F1-score gibi değerlendirme metrikleri kullanılarak analiz edilmiştir.

Ayrıca veri setindeki sınıf dengesizliği problemi dikkate alınarak bazı modellerde SMOTE yöntemi uygulanmış ve model performansları karşılaştırılmıştır.

5.2.1 Logistic Regression

Logistic Regression, ikili sınıflandırma problemlerinde yaygın olarak kullanılan doğrusal tabanlı bir makine öğrenmesi algoritmasıdır. Model, bağımsız değişkenler ile hedef değişken arasındaki ilişkiyi olasılıksal olarak modellemektedir.

Bu çalışmada Logistic Regression modeli kullanılarak müşterilerin vadeli mevduat kampanyasına olumlu yanıt verip vermeyeceği tahmin edilmeye çalışılmıştır. Model performansı çeşitli değerlendirme metrikleri kullanılarak analiz edilmiştir.

```
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import confusion_matrix, classification_report, accuracy_score

log_model = LogisticRegression(max_iter=2000)

log_model.fit(X_train, y_train)

y_pred_log = log_model.predict(X_test)

print("--- Logistic Regression Sonuçları ---")
print(f"Doğruluk Skoru (Accuracy): {accuracy_score(y_test, y_pred_log):.4f}")
print("\nSınıflandırma Raporu:\n", classification_report(y_test, y_pred_log))
```

```
--- Logistic Regression Sonuçları ---
Doğruluk Skoru (Accuracy): 0.8998

Sınıflandırma Raporu:
              precision    recall  f1-score   support

     0       0.91         0.99         0.95         7312
     1       0.67         0.22         0.33          925

 accuracy          0.90         0.90         0.90         8237
 macro avg         0.79         0.60         0.64         8237
 weighted avg         0.88         0.90         0.88         8237
```

Kod Bloğu 7. Logistic Regression Modelinin Eğitilmesi ve Performans Sonuçları

Logistic Regression modeli sonucunda yaklaşık %89.98 doğruluk oranı elde edilmiştir. Modelin çoğunluk sınıfı üzerinde yüksek başarı gösterdiği gözlemlenmiştir. Ancak azınlık sınıfında recall ve F1-score değerlerinin daha düşük olduğu dikkat çekmektedir. Bu durum veri setindeki sınıf dengesizliğinin model performansı üzerindeki etkisini göstermektedir.

5.2.2 Random Forest

Random Forest algoritması, birden fazla karar ağacının birleşiminden oluşan topluluk öğrenmesi (ensemble learning) tabanlı bir makine öğrenmesi yöntemidir. Algoritma, farklı karar ağaçlarının sonuçlarını birleştirerek daha kararlı ve güçlü tahminler üretmektedir.

Bu çalışmada Random Forest modeli kullanılarak müşteri kampanya yanıtları tahmin edilmiş ve model performansı çeşitli değerlendirme metrikleri ile analiz edilmiştir. Ayrıca sınıf dengesizliğinin etkisini azaltmak amacıyla class_weight parametresi kullanılmıştır.

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, accuracy_score

rf_model = RandomForestClassifier(n_estimators=100, class_weight='balanced', random_state=42)

rf_model.fit(X_train, y_train)

y_pred_rf = rf_model.predict(X_test)

print("--- Random Forest Sonuçları ---")
print(f"Doğruluk Skoru (Accuracy): {accuracy_score(y_test, y_pred_rf):.4f}")
print("\nSınıflandırma Raporu:\n", classification_report(y_test, y_pred_rf))

--- Random Forest Sonuçları ---
Doğruluk Skoru (Accuracy): 0.8909

Sınıflandırma Raporu:
              precision    recall  f1-score   support

     0       0.91       0.97       0.94       7312
     1       0.53       0.26       0.35        925

 accuracy          0.89          0.89          0.89          8237
 macro avg       0.72       0.62       0.64          8237
 weighted avg    0.87       0.89       0.87          8237
```

Kod Bloğu 8. Random Forest Modeli ve Performans Sonuçları

Random Forest modeli sonucunda yaklaşık %89.09 doğruluk oranı elde edilmiştir. Modelin çoğunluk sınıfı üzerinde yüksek performans gösterdiği gözlemlenmiştir. Ancak azınlık sınıfına ait recall değerinin düşük olması, modelin minority class örneklerini tahmin etmede sınırlı kaldığını göstermektedir.

Bununla birlikte Logistic Regression modeline kıyasla daha dengeli bir sınıflandırma performansı elde edildiği görülmektedir.

5.2.3 SMOTE Sonrası Random Forest Modeli

Veri setindeki sınıf dengesizliğinin model performansı üzerindeki etkisini azaltmak amacıyla SMOTE yöntemi uygulanarak eğitim verisi dengelenmiştir. Daha sonra dengelenmiş veri seti üzerinde Random Forest modeli yeniden eğitilmiş ve model performansı analiz edilmiştir.

SMOTE yöntemi sayesinde azınlık sınıfına ait örnek sayısı artırılmış ve modelin minority class üzerindeki öğrenme performansının geliştirilmesi amaçlanmıştır.

```

from imblearn.over_sampling import SMOTE
from sklearn.ensemble import RandomForestClassifier

smote = SMOTE(random_state=42)

X_train_balanced, y_train_balanced = smote.fit_resample(X_train, y_train)
print(f"Yeni Eğitim Seti Dengesi: \n{y_train_balanced.value_counts()}")
rf_balanced = RandomForestClassifier(n_estimators=100, random_state=42)
rf_balanced.fit(X_train_balanced, y_train_balanced)
y_pred_smote = rf_balanced.predict(X_test)
print("--- SMOTE Sonrası Random Forest Sonuçları ---")
print(classification_report(y_test, y_pred_smote))

```

```

Yeni Eğitim Seti Dengesi:
y
0    29233
1    29233
Name: count, dtype: int64
--- SMOTE Sonrası Random Forest Sonuçları ---

```

	precision	recall	f1-score	support
0	0.92	0.95	0.94	7312
1	0.49	0.38	0.42	925
accuracy			0.89	8237
macro avg	0.71	0.66	0.68	8237
weighted avg	0.87	0.89	0.88	8237

Kod Bloğu 9. SMOTE Sonrası Random Forest Modeli Sonuçları

SMOTE işlemi sonrasında modelin azınlık sınıfı üzerindeki recall değerinin arttığı gözlemlenmiştir. Özellikle minority class için recall değerinin 0.26'dan 0.38 seviyesine yükselmesi, modelin azınlık sınıfını daha başarılı tahmin etmeye başladığını göstermektedir.

Bununla birlikte precision değerinde bir miktar düşüş yaşandığı dikkat çekmektedir. Bu durum, sınıf dengeleme işlemlerinde yaygın olarak görülen precision-recall dengesi ile açıklanabilmektedir.

5.2.4 XGBoost Modeli

XGBoost (Extreme Gradient Boosting), gradient boosting yaklaşımını kullanan güçlü ve optimize edilmiş bir makine öğrenmesi algoritmasıdır. Özellikle büyük veri setlerinde yüksek performans göstermesi ve sınıflandırma problemlerinde başarılı sonuçlar üretmesi nedeniyle yaygın olarak kullanılmaktadır.

Bu çalışmada veri setindeki sınıf dengesizliği problemi dikkate alınarak XGBoost modeli içerisinde `scale_pos_weight` parametresi kullanılmıştır. Böylece azınlık sınıfına daha fazla ağırlık verilerek modelin minority class üzerindeki öğrenme performansının artırılması hedeflenmiştir.

```
from xgboost import XGBClassifier
from sklearn.metrics import classification_report

ratio = (y_train == 0).sum() / (y_train == 1).sum()

xgb_model = XGBClassifier(scale_pos_weight=ratio, random_state=42, use_label_encoder=False, eval_metric='logloss')

xgb_model.fit(X_train, y_train)

y_pred_xgb = xgb_model.predict(X_test)

print("--- XGBoost (Dengelenmiş Ağırlıklı) Sonuçları ---")
print(classification_report(y_test, y_pred_xgb))
```

	precision	recall	f1-score	support
0	0.94	0.87	0.90	7312
1	0.36	0.58	0.44	925
accuracy			0.84	8237
macro avg	0.65	0.72	0.67	8237
weighted avg	0.88	0.84	0.85	8237

Kod Bloğu 10. XGBoost Modeli ve Performans Sonuçları

XGBoost modeli sonucunda minority class için recall değerinin 0.58 seviyesine yükseldiği görülmüştür. Bu sonuç, modelin kampanyaya olumlu yanıt veren müşterileri diğer modellere kıyasla daha başarılı şekilde tahmin ettiğini göstermektedir.

Bununla birlikte precision değerinde düşüş yaşandığı gözlemlenmiştir. Bu durum, modelin daha fazla pozitif tahmin üretmesi nedeniyle yanlış pozitif oranının artması ile açıklanabilmektedir.

Genel olarak değerlendirildiğinde XGBoost modelinin azınlık sınıfını öğrenme konusunda diğer modellere göre daha başarılı performans gösterdiği görülmektedir.

5.2.5 Support Vector Machine (SVM)

Support Vector Machine (SVM), sınıflar arasındaki en uygun ayırıcı hiper düzlemi belirlemeye çalışan güçlü bir makine öğrenmesi algoritmasıdır. Özellikle yüksek boyutlu veri setlerinde etkili performans gösterebilmesi nedeniyle sınıflandırma problemlerinde yaygın olarak kullanılmaktadır.

Bu çalışmada doğrusal kernel yapısına sahip SVM modeli kullanılmıştır. Ayrıca veri setindeki sınıf dengesizliğinin etkisini azaltmak amacıyla `class_weight='balanced'` parametresi kullanılmıştır.

```

from sklearn.svm import SVC
from sklearn.metrics import classification_report

svm_model = SVC(kernel='linear', class_weight='balanced', random_state=42)
svm_model.fit(X_train, y_train)

y_pred_svm = svm_model.predict(X_test)

print("--- SVM (Support Vector Machines) Sonuçları ---")
print(classification_report(y_test, y_pred_svm))

```

```

--- SVM (Support Vector Machines) Sonuçları ---
              precision    recall  f1-score   support

      0       0.95         0.66       0.78        7312
      1       0.22         0.73       0.33         925

 accuracy          0.58         0.70       0.67        8237
 macro avg          0.58         0.70       0.56        8237
weighted avg          0.87         0.67       0.73        8237

```

Kod Bloğu 11. SVM Modeli ve Performans Sonuçları

SVM modeli sonucunda minority class için recall değerinin 0.73 seviyesine yükseldiği görülmüştür. Bu sonuç, modelin kampanyaya olumlu yanıt verecek müşterileri yakalama konusunda oldukça başarılı performans gösterdiğini göstermektedir.

Ancak precision değerinin düşük olması nedeniyle modelin yanlış pozitif tahmin sayısında artış meydana geldiği dikkat çekmektedir. Ayrıca genel doğruluk oranının diğer modellere kıyasla daha düşük olduğu gözlemlenmiştir.

Bu durum, sınıf dengesizliği problemlerinde recall ve precision metrikleri arasında oluşan denge (trade-off) ile açıklanabilmektedir.

5.3 Modellerin Karşılaştırılması

Çalışma kapsamında oluşturulan makine öğrenmesi modelleri performans metrikleri açısından karşılaştırılmıştır. Modellerin değerlendirilmesinde accuracy, precision, recall ve F1-score metrikleri dikkate alınmıştır.

Özellikle bankacılık pazarlama problemlerinde minority class olarak değerlendirilen “kampanyaya olumlu yanıt veren müşterilerin” doğru tahmin edilmesi büyük önem taşımaktadır. Bu nedenle yalnızca accuracy değeri değil, recall ve precision metrikleri de detaylı şekilde analiz edilmiştir.

--- Vadeli Mevduat Tahmin Modelleri Stratejik Karşılaştırması ---							
	Model	Accuracy	Precision (İsabet Oranı)	Recall (Yakalama Gücü)	F1-Score (Genel Denge)	Tahmin Edilen "Evet"	Stratejik Değerlendirme
0	Logistic Regression	0.8998	0.6700	0.2200	0.3300	303	Çok Tutucu - Fırsat Kaçırıyor
1	Random Forest (SMOTE)	0.8909	0.4900	0.3800	0.4200	717	Zayıf Denge - Geliştirilmeli
2	XGBoost (Ağırlıklı)	0.8400	0.3600	0.5800	0.4400	1489	EN DENGELİ (Şampiyon)
3	SVM (Balanced)	0.6700	0.2200	0.7300	0.3300	3064	Çok Agresif - Yüksek Maliyet


Tablo 5. Makine Öğrenmesi Modellerinin Stratejik Performans Karşılaştırması

Model sonuçları incelendiğinde Logistic Regression modelinin yüksek doğruluk oranına rağmen minority class örneklerini tahmin etmede yetersiz kaldığı görülmüştür. Random Forest modeli daha dengeli sonuçlar üretmiş olsa da minority class recall değeri sınırlı seviyede kalmıştır.

SMOTE sonrası Random Forest modeli ile minority class performansında iyileşme sağlanmıştır. Ancak en başarılı minority class recall performansının SVM modeli tarafından elde edildiği görülmüştür.

Bununla birlikte SVM modelinin precision değerinin düşük olması nedeniyle yanlış pozitif tahmin sayısında artış meydana gelmiştir. Genel performans dengesi açısından değerlendirildiğinde XGBoost modelinin precision-recall dengesi bakımından en başarılı model olduğu sonucuna ulaşılmıştır.

Modellerin Hata Matrisi (Confusion Matrix) Karşılaştırması



Şekil 9. Makine Öğrenmesi Modellerine Ait Confusion Matrix Karşılaştırmaları

Confusion matrix sonuçları incelendiğinde modellerin majority ve minority class üzerindeki davranışlarının farklılık gösterdiği görülmektedir. Logistic Regression modelinin yanlış negatif sayısının yüksek olduğu dikkat çekerken, SVM modelinin minority class örneklerini daha başarılı şekilde yakaladığı gözlemlenmiştir.


XGBoost modeli precision ve recall dengesi açısından daha dengeli sonuçlar üretirken, SMOTE sonrası Random Forest modelinin minority class performansında iyileşme sağladığı görülmektedir.

Genel olarak değerlendirildiğinde modeller arasında farklı performans dengeleri bulunduğu ve model seçiminin iş hedeflerine göre değişebileceği sonucuna ulaşılmıştır.

5.4 XGBoost Modelinde Özellik Önem Düzeyleri

Makine öğrenmesi modellerinin yalnızca yüksek performans göstermesi değil, aynı zamanda karar mekanizmalarının açıklanabilir olması da büyük önem taşımaktadır. Bu nedenle XGBoost modeli üzerinde özellik önem düzeyleri analizi gerçekleştirilmiştir.

Özellik önem düzeyleri sayesinde modelin tahmin sürecinde hangi değişkenlere daha fazla ağırlık verdiği analiz edilmiştir. Böylece müşterilerin vadeli mevduat kampanyasına olumlu yanıt verme olasılığını etkileyen temel faktörler belirlenmiştir.



Şekil 10. XGBoost Modelinde Özellik Önem Düzeyleri

Şekil 10 incelendiğinde XGBoost modelinde en yüksek önem düzeyine sahip değişkenin nr.employed olduğu görülmektedir. Bunun yanı sıra ekonomik göstergeler, iletişim zamanı ve geçmiş kampanya bilgileri de model karar mekanizması üzerinde önemli etkiye sahip olmuştur.

Özellikle pdays_contacted, poutcome_success ve bazı ay değişkenlerinin yüksek önem skorlarına sahip olması, müşterilerin geçmiş iletişim geçmişi ve kampanya zamanlamasının müşteri davranışları üzerinde etkili olduğunu göstermektedir.

Ayrıca feature engineering sürecinde oluşturulan değişkenlerden biri olan age_group_orta değişkeninin de model tarafından önemli faktörlerden biri olarak değerlendirildiği görülmektedir. Bu durum, özellik mühendisliği sürecinin model performansına katkı sağladığını desteklemektedir.

6. Sonuç ve Değerlendirme

Bu çalışmada bankacılık sektöründe gerçekleştirilen doğrudan pazarlama kampanyalarında müşterilerin vadeli mevduat hesabı açma davranışlarının tahmin edilmesi amacıyla çeşitli makine öğrenmesi modelleri geliştirilmiştir. Çalışma kapsamında veri temizleme, aykırı değer analizi, özellik mühendisliği, encoding ve sınıf dengesizliği yönetimi gibi veri ön işleme süreçleri uygulanmıştır.

Veri seti üzerinde gerçekleştirilen analizler sonucunda müşteri davranışlarını etkileyen önemli değişkenler belirlenmiş ve farklı makine öğrenmesi algoritmalarının performansları karşılaştırılmıştır. Logistic Regression, Random Forest, SMOTE destekli Random Forest, XGBoost ve SVM modelleri kullanılarak sınıflandırma işlemleri gerçekleştirilmiştir.

Model sonuçları incelendiğinde her algoritmanın farklı güçlü yönleri sahip olduğu görülmüştür. Logistic Regression modeli yüksek doğruluk oranı sağlamasına rağmen minority class tahminlerinde sınırlı performans göstermiştir. Random Forest modeli daha dengeli sonuçlar üretmiş, SMOTE uygulaması sonrasında minority class başarısında artış gözlemlenmiştir.

XGBoost modeli precision ve recall dengesi açısından en başarılı modellerden biri olarak öne çıkmıştır. Özellikle kampanyaya olumlu yanıt veren müşterilerin tahmin edilmesinde başarılı performans göstermiştir. SVM modeli ise minority class için en yüksek recall değerini elde etmiş ancak yanlış pozitif tahmin oranının artması nedeniyle operasyonel maliyet açısından daha agresif bir yapı sergilemiştir.

Gerçekleştirilen özellik önem analizi sonucunda ekonomik göstergeler, iletişim zamanı, geçmiş kampanya bilgileri ve yaş segmentlerinin müşteri davranışları üzerinde önemli etkiye sahip olduğu belirlenmiştir. Özellikle nr.employed, pdays_contacted, month_oct ve poutcome_success değişkenlerinin model karar mekanizmasında yüksek önem düzeyine sahip olduğu görülmüştür.

Elde edilen sonuçlar doğrultusunda makine öğrenmesi yöntemlerinin bankacılık sektöründeki pazarlama stratejilerine önemli katkılar sağlayabileceği değerlendirilmiştir. Geliştirilen modeller sayesinde müşteri hedefleme süreçleri optimize edilerek operasyonel maliyetlerin azaltılması ve kampanya başarı oranlarının artırılması mümkün olabilecektir.

Gelecek çalışmalarda farklı veri setlerinin kullanılması, hiperparametre optimizasyonu, derin öğrenme tabanlı yöntemlerin uygulanması ve gerçek zamanlı tahmin sistemlerinin geliştirilmesi önerilmektedir. Ayrıca müşteri davranışlarını etkileyebilecek ek finansal ve davranışsal değişkenlerin modele dahil edilmesiyle daha güçlü tahmin performansları elde edilebilir.

Kaynakça

1. UCI Machine Learning Repository. *Bank Marketing Dataset*.
2. Scikit-learn Documentation.
3. XGBoost Documentation.
4. Imbalanced-learn Documentation (SMOTE).
5. Pandas Documentation.
6. NumPy Documentation.
7. Matplotlib Documentation.
8. Seaborn Documentation.
9. Kaggle. *Bank Marketing Classification Dataset*.
10. ChatGPT. OpenAI destekli yapay zekâ aracı üzerinden teknik destek ve kod geliştirme süreçlerinde yararlanılmıştır.